

基于深度学习的交通流数据插补预测系统设计

物联网工程 1 班 1616520139 陈家辉 指导教师 张玺君 副教授

摘 要

本次毕业设计提出了一种名为 LSTM-R 模型来进行交通流数据缺失值的插补,通过对交通流数据进行随机缺失,并采用该模型来对缺失值进行插补,可以提高插补值的精确度,以便为交通流量的短时预测做铺垫。在处理完缺失值的基础上,对于交通流预测问题,本文提出一种基于 LSTM 的生成对抗网络作为解决该问题的模型,通过 BP 网络作为生成对抗网络的判别器,LSTM 作为生成对抗网络的生成器来进行短时交通流量的预测。通过实验仿真,在纽约高速路交通流数据集上进行验证,证明了该深度学习模型在缺失值插补预测系统上具有较好的效果。

关键词: 深度学习; 生成对抗网络; 交通流短时预测; LSTM; 缺失值

Abstract

This article proposes a model named LSTM-R to interpolate the missing values of traffic flow data. The accuracy of the interpolated values is improved by this model in order to pave the way for the short-term prediction of traffic flow. On the basis of dealing with missing data, as for the traffic flow prediction question, this article designs a Generative Adversarial Network based on as a model to solve this problem, it uses a back propagation neural network (BP) as a discriminator of generative adversarial network and the long short-term memory as the Generator of generative adversarial network to predict the traffic flow in the future. Through experimental simulation, it is proved on the highway traffic flow dataset of New York, which proves that the deep learning model has good effect on the missing value interpolation prediction system.

Keywords: deep learning ; Generative Adversarial Networks; short-term traffic flow prediction; LSTM; missing value;

一、概述

通过传感器采集到的交通流数据集往往有很多缺失值,通过建立有效的模型对缺失值进行插补可以为交通流短时预测提高精确度。短时交通流预测在智能交通系统中扮演着至关重要的作用,其无论是系统中扮演者一个不可缺少的角色,其无论是对完善交通信息服务系统提供有效指导,还是对城市智能化的发展提高一定的服务基础,都具有很大的研究价值,逐渐发展成为当今交通领域内探究的一个热点。

二、基于 LSTM-R 交通流缺失值插补

(一) 数据预处理

先通过 Min-Max 方法对交通流数据进行归一化处理,然后对数据集进行人为随机缺失 20%的数据集,并且通过采用平均绝对误差 MAE,平均绝对百分比误差 MAPE,均方根误差 RMSE 来进行插补后的值和真实值进行精度的比较,以评估 LSTM-R 模型的好坏。

(二) 模型定义

如公式 1 所示,在该模型中定义 M_t 为缺失值矩阵。如果 t 时刻的观测值存在,则 M_t 的值为 0,代表此刻无缺失值;如果 t 时刻的观测值不存在,则 M_t 的值为 1,代表此刻有缺失值,如公式 (1) 所示。

$$M_t = \begin{cases} 0, & \text{观测值无缺失} \\ 1, & \text{观测值缺失} \end{cases} \quad (1)$$

如公式 (2) 所示,定义 I_t 为当前时刻 t_i 和上次观察值之间的时间差矩阵。

$$I_t = \begin{cases} 0, & t_i = 0 \\ t_i - t_{i-1}, & M_t = 0 \text{ \& } t_i > 0 \\ t_i - t_{i-1} + I_{t-1}, & M_t = 1 \text{ \& } t_i > 0 \end{cases} \quad (2)$$

该公式 (2) 表明 t_i 时刻的观测值距离上次观测值存在的时间间隔的值为 I_{t_i} 。

定义 LSTM 中记忆门的衰减系数为：

$$r_t = e^{-\max(W_r \bullet I_t + b_r, 0)} \quad (3)$$

其中 W_r 和 b_r 是需要进行训练的参数。




图 1 LSTM-R 结构图

LSTM-R 结构如图 1 所示由公式 (4) 到 (7) 可知，每一个时间步中，先将 x_t 和上一步 LSTM 结构输出的 h_t 分别送入输入门，遗忘门，输出门和记忆门内，其中经过输入门，遗忘门和输出门后，需要将数据进行 *sigmoid* 激活函数处理，而记忆门输出的数据后需要进行 *tanh* 激活函数处理。

$$i_t = \sigma(w_{xi} \bullet x_t + w_{hi} \bullet h_{t-1} + b_i) \quad (4)$$

$$f_t = \sigma(w_{xf} \bullet x_t + w_{hf} \bullet h_{t-1} + b_f) \quad (5)$$

$$o_t = \sigma(w_{xo} \bullet x_t + w_{ho} \bullet h_{t-1} + b_o) \quad (6)$$

$$\tilde{c}_t = \phi(w_{xc} \bullet x_t + w_{hc} \bullet h_{t-1} + b_c) \quad (7)$$

由公式 (8) 可知，通过遗忘门与上一时间步记忆门输出信息 c_{t-1} 数乘后和输入门与当前记忆门输出的值 \tilde{c}_t 进行数乘后相加，最后得到该时间步记忆门的输出。

$$c_t = f_t * c_{t-1} * r_t + i_t * \tilde{c}_t \quad (8)$$

由公式 (9) 可知，而该时间步的隐含信息 h_t 则通过记忆门输出的数据经过 *tanh* 层激活后与输出门进行数乘后得到的。

$$h_t = o_t * \phi(c_t) \quad (9)$$

由于在 LSTM-R 中，如图 1 所示增加了记忆门的衰减系数 r_t ，所以通过公式修正预测的值 x_t 。

$$x_t = m * x_t + (1 - m) * r_t * x_{t'} + (1 - m) * (1 - r_t) * x_{t''} \quad (10)$$

(三) 模型效果

通过 Mxnet 深度学习框架对 LSTM-R 进行训练，采用一层 LSTM-R 结构，其隐层神经元个数 100，其中学习率 lr 为 0.001, 训练批次 batchsize 为 32, 训练次数为 100 次，采用 Adam 优化函数。插补的值效果如图 2 所示。其中红色的曲线为插补出来的值，可以看出和真实值（蓝色曲线）很贴近。




图 2 LSTM-R 模型插补值的效果

三、基于 GAN-LSTM 短时交通流预测

(一) 数据预处理

先对数据集进行 Z-score 规范化处理, 然后通过阈值为 0.05 的 Sym17 小波降噪函数对其进行降噪处理, 然后分为 80% 的训练集, 20% 的测试集, 并进行模型的训练。

(二) 模型定义

GAN-LSTM 是由一个生成器和判别器组成的生成对抗网络结构。其中生成器为一层的 LSTM 结构, 判别器为 3 层的 BP 神经网络。GAN-LSTM 模型要同时对生成器和判别器的损失函数进行优化, 公式如下:

$$g_{mse} = \frac{1}{m} \sum_{t=1}^m (x'_{t+1} - x_{t+1}) \quad (11)$$

$$g_{loss} = \frac{1}{2} D([(x_1, x_2, \dots, x_t, x'_{t+1}]) - c)^2 \quad (12)$$

$$D_{loss} = \frac{1}{2} D([(x_1, x_2, \dots, x_t, x_{t+1}]) - a]^2 + \frac{1}{2} D([(x_1, x_2, \dots, x_t, x'_{t+1}]) - b]^2 \quad (13)$$

$$G_{loss} = \lambda_1 g_{mse} + \lambda_2 g_{loss} \quad (14)$$

将 $[x_1, x_2, \dots, x_t]$ 送入生成器中可得到 x'_{t+1} , x'_{t+1} 和 x_{t+1} 组成伪造序列 $[x_1, x_2, \dots, x_t, x'_{t+1}]$, 而 $[x_1, x_2, \dots, x_t]$ 和 x_{t+1} 组成真实序列 $[x_1, x_2, \dots, x_t, x_{t+1}]$, 然后分别送入判别器中进行判别, 并将得到的梯度反馈给生成器和判别器中。其中公式 (11) 到 (14) 为生成器和判别器损失函数公式。

(三) 参数设置

设置超参数 $a=c=1, b=0$, λ_1 为 0.5, λ_2 为 0.5, 生成器和判别器损失函数均采用 Adam 优化函数, 其中学习率分别为 0.001, 0.0001, 训练批次 batchsize 为 128, 生成器采用一层 LSTM 结构, 其中 LSTM 隐层神经元个数为 256, 判别器中间的神经元个数分别为 72, 100, 10, 模型训练次数为 1000 次。

(四) 实验结果

LSTM, BP 以及 GAN-LSTM 模型在预测周期为 5 分钟下的预测精度如表 1 所示。从表中可以看出 GAN-LSTM 比其他两种模型预测精度都要高, 其中, GAN-LSTM 模型相比于 LSTM 模型, 其 MAE, MAPE 以及 RMSE 在时间间隔为 5 分钟的情况下分别提高了 4.34, 1.97% 以及 9.48。相比于 BP 网络, 其 MAE, MAPE 以及 RMSE 在时间间隔为 5 分钟的情况下分别提高了 4.36, 1.03% 以及 5.5。可知 GAN-LSTM 在交通流预测方面具有比较好的效果。

表 1 BP, LSTM 以及 GAN-LSTM 的预测精度

Type	MAE	MAPE	RMSE
BP	11.05	16.32%	13.96
LSTM	10.98	17.26%	17.94
GAN-LSTM	6.64	15.29%	8.46

四、基于 GAN-LSTM-R 交通流插补预测系统设计

由于 LSMT-R 对缺失值插补较好, 本文通过将缺失值处理后的数据送入 GAN-LSTM 交通流短时预测模型中进行训练, 并和 LSTM 以及 BP 算法作对比, 以评估缺失值处理的效果是否会影响到 GAN-LSTM 模型的稳定性。

通过采用 80% 的数据进行训练, 20% 的数据进行测试后, 可得到如表 2 所示结果。

表 2 BP, LSTM 以及 GAN-LSTM 的预测精度

Type	MAE	MAPE	RMSE
BP	6.14	15.33%	7.64
LSTM	6.75	14.43%	8.62
GAN-LSTM	3.15	6.19%	4.77

这表明采用 GAN-LSTM 模型相比于其他两种单一传统的模型, 其预测精度大大提高, 可以证明 GAN-LSTM 在短时交通流预测方面是具有鲁棒性的。

五、总 结

根据任务书, 查阅了相关文献, 学习了主流的深度学习框架, 能够通过这些框架来进行模型的建立和提高传统模型的二次开发编程能力。将自己设计建立的模型运用到交通流数据集中, 这样可以加深对深度学习模型的理解, 同时也能够学习到如何将深度学习模型更好的运用到生活实际当中去, 这样才能更大程度地发挥深度学习的优点, 并让其更好地服务于我们。

参 考 文 献

- [1] 李锋,申在明.基于指数平滑法的交通量检测设备短期缺失值插补方法分析[J].交通标准化,2013(09):117-119.
- [2] 刘学刚,张腾飞,韩印.基于 ARIMA 模型的短时交通流预测研究[J].物流科技,2019,42(12):91-94+102.
- [3] 李明明,雷菊阳,赵从健.基于 LSTM-BP 组合模型的短时交通流预测[J].计算机系统应用,2019,28(10):152-156.
- [4] 殷英,张朝元,胡光华等.基于 SVM 的实时交通流模拟与预测系统设计[J].计算机工程与应用,2005,41(10):197-199.
- [5] 孙晓丽,郭艳,李宁,宋晓祥.基于改进 RNN 的多变量时间序列缺失数据填充算法[J].信息技术与网络安全,2019,38(11):47-53.
- [6] 田薇. 交通大数据可视分析研究[D].解放军信息工程大学,2017.
- [7] 伍鑫,黄勃,方志军,刘文竹.序列生成对抗网络在推荐系统中的应用[J/OL].计算机工程与应用:1-6[2020-03-14].
- [8] 韩卫国,王劲峰,胡建军.交通流量数据缺失值的插补方法[J].交通与计算机,2005,23(1):39-42.
- [9] Zhang H, Wang X, Cao J, et al. A hybrid short-term traffic flow forecasting model based on time series multifractal characteristics[J]. Applied Intelligence, 2018, 48(8):2429-2440.
- [10] Zhao Z, Chen W, Wu X, et al. LSTM network: a deep learning approach for short-term traffic forecast[J]. IET Intelligent Transport Systems, 2017, 11(2):68-75.